Opt-Al. Weekly Seminar

Opt-AI. LLM Research Team

Executorch QNN Quantization

Table of Contents

O1 LLM KV-Cache
What is KV-Cache


O2 LLM Quantization Calibration

O3 Executorch QNN
QNN Setting & Quantization

O4 Llama Main Code Review About Tokenizer Enc/Dec

O1 LLM KV-Cache







LLM KV-Cache


What is KV-Cache

(Q * K^T) * V computation process with caching






Quantization



Data Type



Data Type


FIXED POINT VS FLOATING POINT


FIXED POINT

- 정수부/소수부로 나누어 저장
- 기존 INTEGER data format과 높은 호환성을 가지고 있어 하드웨어 친화적
- 정수부/소수부 위치 등은 별도 관리 필요
- Uniform distribution 또는 Non-zero mean data(Affine Quantization)에 적합

FLOATING POINT


- 지수부/소수부로 나누어 저장 (0.0078125 → 1.0 * 2^-6)
- INTEGER 대비 하드웨어 구조 복잡
- Laplace distribution에 적합





Symmetric Quantization

- 0을 중심으로 대칭적인 정수 범위에 매핑하는 방식
- Zero-point가 항상 0으로 실수 값이 0이라면 정수 값도 항상 0을 가짐
- 실수 값의 최대, 최소의 크기가 대칭적이라고 가정



$$Q_{x} = round(\frac{X}{S})$$

Affine Quantization

- 입력 값을 Affine Transformation하여 정수 값으로 변환 하는 방식
- Affine Quantization은 Asymmetric Quantization 양자화를 포함하고 있음
- 실수 값이 비대칭적


$$Q_{x} = round(\frac{X}{S} + Z)$$
$$X = S \cdot (Q_{x} - Z)$$

 Q_x : 양자화된 정수 값

X: 원래 실수 값,

S: 실수 값과 정수 값 간의 단위 변환

Z: 실수 값에서 0을 정수 값으로 변환하기 위한 값



$$X = S \cdot (Q_{\chi} - Z)$$


Per-Tensor/Channel Quantization

Per-Channel Quantization

- Tensor의 각 채널마다 독립적인 Scaling factor와 Zero-point 사용해 양자화
- 각 채널의 데이터 분포에 맞춘 Scaling과 Zero-point를 사용하므로 데이터 분포의 차이로 인한 정보 손실 줄임
- 채널마다 별도의 Scaling factor와 Zero-point 가지므로, 메모리 요구량 증가

Per-Tensor Quantization

- Tensor의 모든 값이 동일한 Scaling factor와 Zero-point를 사용해 양자화
- 계산이 단순하며 메모리 요구량이 낮음
- Tensor 내 데이터의 분포가 채널마다 다를 경우, 정확도 손실



Calibration

Calibration


- 양자화를 수행할 [a, b] 범위 설정을 위한 방법
- 실수 값을 정수 값으로 변환하기 전, 데이터의 범위를 분석하고 스케일링을 설정하는 과정

Post-Training Dynamic Quantization

- PTQ의 일환으로, 모델을 훈련한 후 양자화를 적용하는 대표적인 방법
- 모델 Weight는 고정된 정수 값으로 양자화, Activation은 Runtime중에 동적으로 변환

Post-Training Static Quantization


- Weight와 Activation을 모두 정적인 범위를 기반으로 양자화
- Activation 값의 범위를 추정하기 위해 Calibration 데이터 사용



Calibration

Calibration

Observer



Calibration

Quantization-Aware Training (QAT)


- 훈련 과정에서 양자화를 시뮬레이션하며, 모델을 양자화 친화적으로 학습
- 훈련 중 Weight와 Activation을 모두 양자화된 상태로 처리
- 양자화로 발생하는 손실에 모델이 적응할 수 있도록 함
- 정확도는 가장 높을 수 있으나, 훈련 비용과 계산 비용 증가

Min-Max

- 최대값과 최소값을 기준으로 범위 설정 (Weight)
- 간단하고 빠르나, 이상치에 민감

Moving Average Min-Max

- 샘플 데이터의 평균적인 분포를 기준으로 범위 설정 (Activation)
- 이상치 영향을 줄이고, 안정적인 스케일링 제공



```
parser.add_argument(
    "--qnn",
    action="store_true",
    help="Delegate llama2 to qnn backend (Qualcomm), please use it --kv_cahce=True",
)
```

```
parser.add_argument(
       "--pt2e_quantize",
       default=None,
       choices=[
           "xnnpack_dynamic",
          _______qc4",
           "qnn_8a8w",
           "qnn_16a16w",
           "qnn_16a4w",
           "coroml chull
           "coreml_8a_c8w",
           "coreml_8a_c4w",
           "coreml_baseline_8a_c8w",
           "coreml_baseline_8a_c4w",
           "vulkan_8w",
       ],
```

QNN Quantization

```
def _export_llama(modelname, args) -> LLMEdgeManager: # noqa: C901
   _validate_args(args)
   pt2e_quant_params, quantizers, quant_dtype = get_quantizer_and_quant_params(args)

# export_to_edge
builder_exported_to_edge = (
   _prepare_for_llama_export(modelname, args)
   .export()
   .pt2e_quantize(quantizers)
   .export_to_edge(
   )
```

print(args.pt2e_quantize, args.quantization_mode, pt2e_quant_params)
qnn_16a8w None None

```
def get_qnn_quantizer(
    pt2e_quantize: str,
    quantization_mode: Optional[str] = None,
    is_qat: bool = False,
    backend, quant_config = pt2e_quantize.split("_")
    מאשרונ (
       backend == "qnn"
    ), f"The quantization config is for backend {backend} instead of qnn."
    qnn quantizer = QnnQuantizer() # pyre-fixme[16]
    qnn_quantizer.set_per_channel_conv_quant(enable=True)
    qnn_quantizer.set_per_channel_linear_quant(enable=True)
    custom annotations = ()
    if quant_config == "8a8w":
        quant_dtype = QuantDtype.use_8a8w # pyre-fixme[16]
       qnn_quantizer.set_quant_config(quant_dtype, is_qat=is_qat)
    elif quant_config == "16a16w":
        quant_dtype = QuantDtype.use_16a16w # pyre-fixme[16]
        logging.warning(
            "Disable per channel quantization for linear and conv due to the error with QNN HTP 16a16w."
        qnn_quantizer.set_per_channel_conv_quant(enable=False)
        qnn_quantizer.set_per_channel_linear_quant(enable=False)
        qnn_quantizer.set_quant_config(
    elif quant_config == "16a4w":
        quant_dtype = QuantDtype.use_16a4w
        qnn_quantizer.set_quant_config(
            quant_dtype, is_gat=is_gat, act_observer=MinMaxObserver
        custom_annotations = (custom_annotate_llama_matmul_16a8w,)
    else:
        raise AssertionError(
           f"No support for quant type {quant_config}. Support 8a8w, 16a16w and 16a4w."
    assert (
        quantization_mode is None
    ), "Currently qnn backend only supports QnnQuantizer via pt2e flow"
    qnn_quantizer.add_custom_quant_annotations(custom_annotations)
    return qnn_quantizer, quant_dtype
```

```
class QnnQuantizer(Quantizer):
    SUPPORTED_OPS: Set = set(OP_ANNOTATOR.keys())

def __init__(self):
    super().__init__()
    self.quant_ops: Set[OpOverload] = self.SUPPORTED_OPS.copy()

self.is_qat = False
    self.quant_dtype = QuantDtype.use_8a8w
    self.quant_config: QuantizationConfig = get_8a8w_qnn_ptq_config()
    self.per_channel_quant_config = get_ptq_per_channel_quant_config()
    self.use_per_channel_weight_quant_ops: Set[OpOverload] = set()

self.custom_quant_annotations: Sequence[Callable] = []
    self.discard_nodes: Set[str] = set()
```

```
quant_config_dict = {
    (QuantDtype.use_16a16w, False): (
       get_16a16w_qnn_ptq_config,
       get_ptq_per_channel_quant_config(torch.uint16, torch.int16),
    (QuantDtype.use_16a8w, False): (
       get_16a8w_qnn_ptq_config,
       get_ptq_per_channel_quant_config(torch.uint16, torch.int8),
    (QuantDtype.use_16a4w, False): (
       get_16a4w_qnn_ptq_config,
       get_ptq_per_channel_quant_config(torch.uint16, "int4"),
   (QuantDtype.use_8a8w, False): (
       get_8a8w_qnn_ptq_config,
       get_ptq_per_channel_quant_config(),
    (QuantDtype.use_16a4w, True): (
       get_16a4w_qnn_qat_config,
       get_qat_per_channel_quant_config(torch.uint16, "int4"),
    (QuantDtype.use_8a8w, True): (
       get_8a8w_qnn_qat_config,
       get_qat_per_channel_quant_config(),
```

. .

def get 8a8w gnn ptg config(

dtype=torch.uint8,

dtype=torch.int8,

) -> QuantizationConfig:

ascheme=(

 $ch_axis=0$,

ch axis=0,

QNN Quantization

```
bias_quantization_spec = QuantizationSpec(
                                              dtype=torch.int32,
                                              quant_min=torch.iinfo(torch.int32).min,
                                              quant_max=torch.iinfo(torch.int32).max,
qscheme=torch.per_tensor_symmetric
                                              observer_or_fake_quant_ctr=MinMaxObserver.with_args(**extra_args),
print(act_quantization_spec)
QuantizationSpec(dtype=torch.uint8,
observer_or_fake_quant_ctr=functools.partial(<class'torch.ao.quantization.observer.MovingAverageMinMaxObserver'>, eps=0.000244140625){},
quant_min=None, quant_max=None, qscheme=torch.per_tensor_affine, ch_axis=0, is_dynamic=False)
print(weight quantization spec)
QuantizationSpec(dtype=torch.int8, observer_or_fake_quant_ctr=functools.partial(<class 'torch.ao.quantization.observer.MinMaxObserver'>,
eps=0.000244140625){}, quant_min=-127, quant_max=127, qscheme=torch.per_tensor_symmetric, ch_axis=0, is_dynamic=False)
print(bias quantization spec)
QuantizationSpec(dtype=torch.int32, observer_or_fake_quant_ctr=functools.partial(<class 'torch.ao.quantization.observer.MinMaxObserver'>,
eps=0.000244140625){}, quant min=-2147483648, quant max=2147483647, qscheme=torch.per tensor symmetric, ch axis=None, is dynamic=False)
```

act_symmetric: bool = False, act_observer=MovingAverageMinMaxObserver

observer_or_fake_quant_ctr=act_observer.with_args(**extra_args),

observer_or_fake_quant_ctr=MinMaxObserver.with_args(**extra_args),

torch.per_tensor_symmetric if act_symmetric else torch.per_tensor_affine


extra_args: Dict[str, Any] = {"eps": 2**-12}

weight quantization_spec = QuantizationSpec(

quant_min=torch.iinfo(torch.int8).min + 1, quant_max=torch.iinfo(torch.int8).max, qscheme=torch.per_tensor_symmetric,

act_quantization_spec = QuantizationSpec(

04 Llama Main Code Review



Actual implementation

개념

Request Generation with "Prompt"

		Runner	
Tokenizer	2	Prefiller 3	Generator 5 Text decoder runner 생략 Module

범례	설명	
1	추론을 시작하기전 하나의 토큰을 미리 추론 요청	
2	입력된 텍스트를 토크나이징	
3	토큰을 모델에 입력 후 하나의 결과를 얻음	
4	3의 결과를 추가한 뒤 'EOS' 토큰이 나올 때 까지 추론 요청	
5	실제 추론 수행	

Actual implementation

KV-Cache?

```
Runner::Runner(const std::string& model path,
               const float
                                 temperature)
    : temperature_(temperature),
      module_(std::make_unique<Module>(model_path, Module::LoadMode::File)),
      tokenizer_path_(tokenizer_path), metadata_({
                                          {kEnableDynamicShape, false},
                                          {kMaxSeqLen, 128},
                                          {kUseKVCache, true},
                                          {kUseSDPAWithKVCache, false},
                                      })
    ET_LOG(Info,
           "Creating LLaMa runner: model_path=%s, tokenizer_path=%s",
           model_path.c_str(),
           tokenizer_path.c_str());
```

```
::executorch::runtime::Result<exec aten::Tensor>
TextDecoderRunner::step(TensorPtr& tokens, TensorPtr& start_pos)
    if (use_kv_cache_)
        auto outputs res = module ->forward({tokens, start pos});
        ET_CHECK_OK_OR_RETURN_ERROR(outputs_res.error());
        ET CHECK MSG(outputs res.get().size() == 1,
                     "More then one output returned from executing LLM.");
        ET_CHECK_MSG(outputs_res.get()[0].isTensor(),
                     "Non Tensor Output returned from executing LLM"):
        return outputs_res.get()[0].toTensor();
    else
        (void)start pos; // unused
        auto outputs res = module ->forward(tokens);
        ET CHECK OK OR RETURN ERROR(outputs res.error());
        ET CHECK MSG(outputs res.get().size() == 1,
                     "More then one output returned from executing LLM.");
```

Actual implementation

KV-Cache!

```
Tensor& sdpa_with_kv_cache_out(KernelRuntimeContext&
                                                      ctx,
                              const Tensor&
                                                      q_projected,
                              const Tensor&
                                                      k_projected,
                              const Tensor&
                                                      v_projected,
                              Tensor&
                                                      key_cache,
                                                      value_cache,
                              Tensor&
                              const int64_t
                                                      start_pos,
                              const int64_t
                                                      seq_len,
                              const optional<Tensor>& attn_mask,
                              const double
                                                      dropout_p,
                                                      is_causal,
                              const bool
                              const optional<double> scale,
                              Tensor&
                                                     output);
```

변환 된 모델 어딘가에 존재함..

End.